

## 汇报 2

基于规则的 OCR 清洗策略与 VLM 描述能力对比

颜熙辰

2025 年 11 月 23 日

# 目录

- 1 任务一：基于混合策略的图像水印清洗
- 2 任务二：多模态大模型 (VLM) 图片描述能力评测

# 任务一：核心问题与解决方案

**背景：**网络爬取的图片（如微博、小红书）底部常附带包含无关信息（UID、来源标识、广告）的水印条，严重影响后续数据训练质量。

**难点：**

- 水印透明度高，背景复杂，OCR 难以直接识别。
- 纯规则裁剪容易误伤正常图片内容。
- 纯 LLM 识别成本过高，且对坐标判断不精确。

**解决方案：**采用 “图像增强 + OCR 预检 + 规则/LLM 混合决策”

# 关键技术点 1：针对性图像增强

为解决水印“隐形”问题，代码实现了 `enhance_watermark` 函数。  
原理分析：

## ① CLAHE (自适应直方图均衡化):

- `clipLimit=3.0, tileGridSize=(8,8)`
- 作用：在局部小块内增强对比度。相比全局均衡化，它能把隐藏在复杂背景（如树叶、阴影）中的浅色水印“拉”出来。

## ② Gamma 校正 (Gamma=1.5):

- 作用：非线性提亮暗部细节。由于水印通常半透明且叠加在底部，Gamma 校正能显著提升文字边缘的清晰度。

```
1 # 核心代码片段
2 clahe = cv2.createCLAHE(...)
3 enhanced = clahe.apply(gray)
4
5 gamma = 1.5
6 table = np.array([...])
7 enhanced = cv2.LUT(enhanced, table
8 )
```

## 关键技术点 2：混合决策逻辑 (Hybrid Decision)

代码并未完全依赖 AI，而是设计了分级处理策略，兼顾效率与准确率。

### 处理流程 (Pipeline)

- ① **物理裁剪预判**：仅提取图片底部 30% 区域进行分析，减少计算量。
- ② **OCR 扫描**：使用 RapidOCR (CPU 版) 识别增强后的文字。
- ③ **一级决策 (规则引擎 - 高效)**：
  - 匹配关键词黑名单 (如“微博”, “uid”, “©”, “摄影”)。
  - 为何有效：90% 的水印包含固定关键词。一旦命中，直接根据 OCR 坐标计算裁剪比例，无需调用 LLM，速度极快且裁剪位置像素级精准。
- ④ **二级决策 (LLM 仲裁 - 兜底)**：
  - 仅当 OCR 识别出文字但不在黑名单中时 (如路牌、衣服文字)，调用 Doubao 模型进行语义判断。
  - 避免了“一刀切”导致的误裁。

## 任务二：评测概况

**评测目标：**对比不同大模型在生成“详细图片描述 (Caption)”时的准确性、细节捕捉能力及幻觉程度。

**测试集：**5 张风格迥异的图片（风景、错位摄影、人文街拍、静物）。

**参测模型：** Gemini, GPT, Grok。

**Prompt：**统一要求生成详细的 JSON 格式描述，包含场景、光影、主体细节等。

# 模型表现对比：Gemini

特点：结构化最强，分析像“理科生”

- 优势：

- 字段拆分极细：独有 world\_knowledge（世界知识）和 safety\_and\_constraints（安全检测）字段。
- 推理能力：在“老鹰与人”的错位图中，明确指出了“Optical Illusion”（视觉错觉）和“Forced Perspective”（强迫透视），分析最为精准。
- OCR 结合：对图片中的文字（如葡萄价格牌）有专门的 visual\_text 字段分析。

- 不足：语言风格偏向数据库条目，略显生硬，缺乏文学性。

典型案例（图 2 老鹰）：准确识别出是“人鹰合一”的错觉，并推测背景可能为驯鹰活动。

# 模型表现对比：GPT

**特点：叙事感最强，文笔像“摄影师”**

- **优势：**
  - **氛围营造：** atmosphere\_and\_mood 字段描写极佳（如 “Nostalgic” , “Cinematic”）。
  - **光影描述：** 对光线的描写（“Golden Hour”, “Dappled effect”）非常细腻，适合用于指导文生图模型的 Prompt 优化。
  - **连贯性：** Overall Caption 是一段完整的、可读性极高的文章。
- **细节：** 在“葡萄车”图中，不仅识别了价格，还推测了生活气息（“Slice-of-life atmosphere”）。



# 模型表现对比：Grok

特点：简洁直观，带有“极客”属性

- 优势：

- 色彩量化：唯一一个在描述中直接给出颜色 Hex 代码（如 #FFD700）的模型，这对设计参考非常有价值。
- 风格识别：倾向于识别图片的“网络属性”，例如将老鹰图描述为“Meme-like”（模因风格），非常接地气。

- 不足：相比前两者，在部分细节的推演上略显保守，描述长度通常较短。

# 横向对比总结

维度	Gemini	GPT	Grok
结构化程度	高 (最佳)	中	中
文学/叙事性	中	高 (最佳)	中
错觉/逻辑推理	极强	强	较强
特殊功能	安全/隐私检测	氛围感描写	Hex 颜色代码
适用场景	数据清洗/打标	文案生成/Prompt 优化	快速检索/设计辅助

表: 三款模型在本次任务中的综合表现对比

# 收工

请哥指正